

# Tarea 01 - Construcción de un pipeline ETL batch en AWS

Arquitectura de Datos en la Nube con Python  
Sesión 1 - Procesamiento Batch en AWS con Glue

| Modalidad  | Fecha de entrega |
|------------|------------------|
| Individual | ___ / ___ / ____ |

## 1. Objetivo

Construir de principio a fin un pipeline ETL batch sobre AWS, partiendo de un archivo de datos crudo y llegando a una tabla consultable con SQL desde Athena. La tarea replica el flujo trabajado en los laboratorios de la sesión, pero sobre un dataset distinto y con transformaciones que usted debe decidir y justificar.

El objetivo de fondo no es repetir los pasos del laboratorio, sino tomar las decisiones de diseño que el laboratorio ya traía resueltas: qué limpiar, por qué columna particionar y cómo catalogar la zona curada.

## 2. Descripción de la tarea

Usted elige uno de los tres datasets entregados y debe llevarlo hasta un modelo consultable, pasando por las siguientes etapas:

- **Ingesta.** Subir el archivo original, sin modificar, a una zona raw en S3.
- **Catalogación de raw.** Registrar el archivo en el Glue Data Catalog para poder leerlo.
- **Transformación.** Un Glue Job en PySpark que aplique al menos tres transformaciones.
- **Escritura.** Guardar el resultado en formato Parquet particionado, en una zona curated.
- **Catalogación de curated.** Registrar la tabla resultante, con el método que usted elija.
- **Consulta.** Validar el resultado con tres consultas SQL en Athena.

## 3. Requisitos técnicos

### 3.1 Fuente de datos

Se le entregan tres datasets listos para descargar y usar, en la carpeta data/tarea01 del repositorio del curso. Elija UNO de los tres. No necesita buscar datos por su cuenta.

| Archivo             | Formato    | Filas | Dominio                                         |
|---------------------|------------|-------|-------------------------------------------------|
| ventas_retail.csv   | CSV        | 2.040 | Ventas de una cadena retail, abril a junio 2025 |
| sensores_iot.json   | JSON Lines | 2.535 | Lecturas de sensores industriales               |
| viajes_taxi.parquet | Parquet    | 3.000 | Viajes de taxi en Lima                          |

Los tres cumplen los requisitos de la tarea: más de 1.000 filas, una columna de fecha y al menos una columna categórica utilizable como criterio de particionado. Los tres contienen además problemas de calidad deliberados.

**Importante.** Detectar esos problemas es parte del trabajo.

Antes de escribir la primera transformación, explore el dataset en Athena y documente en el informe qué encontró: valores nulos, duplicados, categorías escritas de varias formas, valores fuera de rango o campos numéricos guardados como texto. El archivo README.md de la carpeta data/tarea01, que se encuentra en el Github, describe cada dataset e indica dónde conviene mirar, pero no le dirá qué está mal: eso lo descubre ustedes.

Cada dataset plantea un reto propio. El JSON incluye un objeto anidado que deberá aplanar antes de poder particionar por él. El Parquet trae las columnas de fecha guardadas como texto, pese a que el formato sí soporta tipos. El CSV es el más sucio de los tres en cuanto a categorías inconsistentes.

Si prefiere trabajar con un dataset propio, es posible, pero requiere aprobación previa del docente y debe cumplir las mismas condiciones: más de 1.000 filas, una columna de fecha o categoría, y al menos un problema de calidad real.

### 3.2 Organización en S3

Cree un bucket propio con esta estructura mínima:

```
s3://<su-bucket>/
  raw/<dataset>/      archivo original, sin modificar
  curated/<dataset>/  resultado en Parquet particionado
  scripts/            código del Glue Job
  athena-results/     resultados de las consultas
```

La separación entre raw y curated no es decorativa: raw es la evidencia de lo que llegó y nunca se modifica; curated es el dato listo para consumir.

### 3.3 Transformaciones (mínimo tres)

Debe aplicar al menos tres transformaciones de la siguiente lista, y explicar en el informe por qué eligió cada una para su dataset:

| Tipo                | Ejemplo                                                        |
|---------------------|----------------------------------------------------------------|
| Control de calidad  | Filtrar nulos, duplicados o valores fuera de rango             |
| Conversión de tipos | Texto a fecha, texto a numérico, normalizar decimales          |
| Columna derivada    | Clasificar por rangos, calcular un total, extraer año o mes    |
| Normalización       | Unificar mayúsculas, limpiar espacios, estandarizar categorías |
| Agregación          | Agrupar por cliente, producto o periodo                        |
| Enriquecimiento     | Cruzar con una segunda tabla o catálogo                        |

### 3.4 Escritura del resultado

- **Formato:** Parquet. No se acepta CSV en la zona curada.
- **Particionado:** obligatorio, por una columna que usted elija y justifique.

- **Criterio:** la partición debe tener sentido para las consultas que hará después. Una columna con 900 valores distintos sobre 1.000 filas es un mal particionado.

### 3.5 Catalogación de la zona curated

Puede resolverlo de cualquiera de las dos formas vistas en clase:

- **Opción A.** Un segundo Crawler apuntando a la zona curated.
- **Opción B.** El propio Job, usando enableUpdateCatalog al escribir.

Cualquiera de las dos es válida, pero en el informe debe justificar su elección en términos de costo, latencia y de quién controla los datos de esa zona. La justificación vale más que la opción elegida.

### 3.6 Consultas en Athena

Ejecute y documente estas tres consultas sobre la tabla curada:

1. **Consulta de validación.** Demuestre que el problema de calidad que detectó ya no existe (por ejemplo, que la consulta de valores negativos devuelve cero filas).
2. **Consulta analítica.** Una agregación con GROUP BY que responda una pregunta de negocio concreta sobre su dataset.
3. **Consulta de particionado.** La misma consulta con y sin filtro por la columna de partición, comparando el valor de Data scanned que reporta Athena en cada caso.

## 4. Entregables

| # | Entregable                                | Formato                     |
|---|-------------------------------------------|-----------------------------|
| 1 | Script del Glue Job, comentado            | archivo .py                 |
| 2 | Informe técnico (máximo 2 a 4 páginas)    | PDF o Word                  |
| 3 | Capturas de evidencia (ver detalle abajo) | imágenes dentro del informe |
| 4 | Enlace u origen del dataset utilizado     | dentro del informe          |

El informe debe contener, como mínimo:

- Descripción del dataset: origen, formato, número de filas y columnas.
- El problema de calidad detectado y cómo lo resolvió.
- Las tres transformaciones aplicadas, con su justificación.
- La columna elegida para particionar y por qué.
- El método de catalogación elegido y su justificación.
- Las tres consultas con sus resultados y la comparación de Data scanned.
- Las respuestas a las preguntas de la sección 5.

Capturas mínimas requeridas:

- Estructura de carpetas del bucket en S3.
- Tabla de raw en el Glue Data Catalog, mostrando el esquema inferido.
- Ejecución del Job en estado Succeeded.
- Carpetas de partición generadas en la zona curated.

- Resultado de cada una de las tres consultas en Athena.

## 5. Preguntas de reflexión

Responda en el informe, de forma breve y con sus propias palabras:

4. ¿Qué tipos infirió el crawler para su dataset? ¿Alguno quedó mal y por qué cree que ocurrió?
5. ¿Cuánta diferencia hubo en Data scanned entre la consulta con filtro de partición y la que no lo tenía? ¿Qué significaría esa diferencia si el dataset tuviera un terabyte?
6. Si mañana llegara un archivo nuevo con datos del día siguiente, ¿qué tendría que volver a ejecutar y qué no? ¿Cambiaría su respuesta según el método de catalogación que eligió?

## 6. Rúbrica de evaluación

| Criterio                 | Qué se evalúa                                                   | Puntos |
|--------------------------|-----------------------------------------------------------------|--------|
| Ingesta y organización   | Bucket con zonas raw y curated correctamente separadas          | 3      |
| Catalogación             | Tabla registrada y funcionando, con justificación del método    | 3      |
| Transformaciones         | Mínimo tres, correctamente implementadas y justificadas         | 5      |
| Escritura y particionado | Parquet particionado con criterio defendible                    | 3      |
| Consultas en Athena      | Las tres consultas, con evidencia y comparación de Data scanned | 3      |
| Informe y evidencias     | Claridad, capturas completas, respuestas a la sección 5         | 3      |
| Limpieza de recursos     | Evidencia de que eliminó los recursos al terminar               | 0      |
| TOTAL                    |                                                                 | 20     |

## 7. Consideraciones importantes

### 7.1 Costos

Completar esta tarea cuesta menos de un dólar si trabaja con un dataset pequeño y elimina los recursos al terminar. Tenga en cuenta que Glue cobra por tiempo de ejecución y Athena por bytes escaneados. Evite dejar crawlers programados: un crawler con frecuencia horaria olvidado genera cobros durante semanas.

### 7.2 Limpieza obligatoria

Al terminar debe eliminar el bucket, los crawlers, el job, la base de datos del catálogo y el rol IAM. Incluya en el informe una captura que evidencie la limpieza. Este punto se califica.

### 7.3 Seguridad

No incluya claves de acceso, tokens ni credenciales en el script, en las capturas ni en el informe. Si sube su trabajo a un repositorio, revise que no queden archivos con credenciales. Un entregable con credenciales expuestas se califica con cero.

## 7.4 Sobre el uso de asistentes de IA

Puede apoyarse en herramientas de IA para escribir o depurar el código. Lo que se evalúa es su criterio: por qué eligió esa transformación, esa partición y ese método de catalogación. Esas justificaciones deben ser suyas y debe poder defenderlas.

## 8. Material de apoyo

Todo lo que necesita está en el repositorio del curso, en la carpeta AWS/sesion1\_procesamiento\_batch:

- **data/tarea01/** - los tres datasets y un README que describe cada uno.
- **lab00\_preparacion\_entorno.md** - creación del bucket, el rol IAM y configuración de Athena.
- **lab01\_crawler\_y\_data\_catalog.md** - cómo catalogar la zona raw y consultarla.
- **lab02\_glue\_job\_y\_crawler\_curated.md** - el Glue Job, el particionado y la catalogación de curated.
- **scripts/etl\_transacciones.py** - el script de clase, útil como punto de partida.

Los laboratorios incluyen una sección de problemas frecuentes con los errores que más aparecen. Revísela antes de preguntar: es probable que su error ya esté ahí.

## Anexo - Estructura sugerida del entregable

```
tarea01_<apellido>/  
  informe.pdf  
  etl_<dataset>.py  
  consultas.sql  
  capturas/  
    01_bucket_s3.png  
    02_catalogo_raw.png  
    03_job_succeeded.png  
    04_particiones_curated.png  
    05_athena_validacion.png  
    06_athena_analitica.png  
    07_athena_particionado.png  
    08_limpieza.png
```

### Lista de verificación antes de entregar

- ☐ Elegí uno de los tres datasets entregados y lo indiqué en el informe.
- ☐ El archivo original está en raw/ sin modificar.
- ☐ El Job aplica al menos tres transformaciones y está comentado.
- ☐ La salida está en Parquet y particionada.
- ☐ La tabla curada responde en Athena.
- ☐ Las tres consultas están documentadas con sus resultados.
- ☐ El informe justifica particionado y método de catalogación.
- ☐ Las preguntas de la sección 5 están respondidas.
- ☐ Los recursos de AWS fueron eliminados y hay evidencia.
- ☐ No hay credenciales en ningún archivo entregado.